Projekt przejciowy

Temat projektu

Wykorzystanie metod uczenia maszynowego do wykrywania anomalii w danych pochodzcych z sieci czujników IoT oraz opracowanie systemu monitorowania, wizualizacji i raportowania wykrytych nieprawidowoci.

Skad grupy

1. Mateusz Buchczyk 272816
2. Remigiusz Szmyt 272819

1 Metodologia zbierania i podziau danych

Pomiary z trzech wzów ESP32 zapisano na serwerze i zsynchronizowano na podstawie czasu odbioru. Dane podzielono chronologicznie na trzy zbiory w proporcji 70/15/15. Najwczeniejsze pomiary przeznaczono do treningu, kolejne do walidacji, a ostatnie do testu.

1.1 Zbieranie danych

System wykorzystuje trzy wzy ESP32: wze z czujnikami AHT20 i BMP280, wze z czujnikiem owietlenia BH1750 oraz wze z akcelerometrem ADXL345. Telemetria jest przesyana przez MQTT do serwera i zapisywana w pliku CSV. W repozytorium plik `data/raw/telemetry.csv` zawiera czas odbioru `received_at`, temat MQTT, identyfikator urzdzenia, nazw kanau, czas urzdzenia `ts_ms`, numer sekwencyjny, warto i jednostk. Jeden wiersz opisuje pojedynczy kana, a nie kompletny wektor wszystkich pomiarów.

Zebrany zbiór obejmuje okoo 39 godzin pomiarów.

1.2 Synchronizacja i reprezentacja pomiarów

Przygotowanie danych prowadzi do wspólnej siatki czasowej o kroku 5 s. Punktem odniesienia jest czas odbioru na serwerze, co umoliwia zestawienie kanaów z rónych urzdze. Nie oznacza to jednoczesnego fizycznego próbkowania: opónienia transmisji i róne czstotliwoci raportowania pozostaj ródem niepewnoci.

Kada przygotowana próbka zawiera sze cech:

1. `AHT20_temperature` – temperatura;
2. `AHT20_humidity` – wilgotno wzgldna;
3. `BMP280_pressure` – cinienie atmosferyczne;

4. `BH1750` – natenie owietlenia;

5. `ADXL345_accel_rms` – raportowana miara RMS przyspieszenia;

6. `ADXL345_accel_max` – raportowana maksymalna warto przyspieszenia.

Znacznik `received_at` suy do uporzdkowania danych i nie jest cech modelu. Dwie miary akcelerometru traktowane s jako osobne kanay.

1.3 Podzia chronologiczny i oczyszczanie

Przyjto chronologiczny podzia obserwacji w proporcji 70/15/15: najwczeniejsza cz suy do uczenia, nastpna do walidacji, a ostatnia do kocowego testu. Nie stosuje si losowego mieszania próbek. Ssiednie odczyty s zalene czasowo, wic losowanie mogoby umieci bardzo podobne fragmenty przebiegu jednoczenie w treningu i ocenie. Podzia chronologiczny lepiej odpowiada uyciu modelu do analizy póniejszych pomiarów. Nie usuwa jednak cakowicie zalenoci midzy zbiorami.

Walidacja suy do analizy zachowania modelu i podejmowania decyzji o parametrach. Zbiór testowy pozostaje przeznaczony do oceny po zakoczeniu tych decyzji i nie powinien suy do dobierania progu. Proporcje dotycz przyjtego podziau chronologicznego; po przygotowaniu i oczyszczaniu liczebnoci nie musz zachowywa ich dokadnie.

Potencjalne wstrzsy usuwa si wycznie z czci treningowej, aby ograniczy uczenie zakóce jako zachowania odniesienia. Z walidacji i testu nie naley usuwa obserwacji tylko dlatego, e s nietypowe: prowadzioby to do sztucznego uatwienia oceny. Regu oczyszczania naley ustali na podstawie treningu i wiedzy o eksperymencie, bez korzystania z póniejszych wyników. Nie jest ona równoznaczna z potwierdzeniem etykiet anomalii.

Liczebnoci zbiorów po przygotowaniu danych przedstawiono w tabeli. Liczebnoci odnosz si do gotowych wektorów szeciu cech, nie do surowych wierszy telemetrii.

Zbiór	Liczba próbek	Liczba cech
Treningowy	19 634	6
Walidacyjny	4 222	6
Testowy	4 222	6